

Otimizando a Programação de Campeonatos de CS:GO: Uma Análise Estratégica de Redes de Competição Baseada em Teoria dos Grafos

Problema: Utilizando a Teoria dos Grafos para Análise Estratégica de Rivalidades e Programação de Campeonatos em Partidas Profissionais de CS:GO.

1th Pedro Henrique Pires Dias
Bacharelado em Engenharia da Computação
CEFET-MG, Campus V
Divinópolis, Brasil
pedro.dias@aluno.cefetmg.br

Resumo: Este estudo explora a aplicação da teoria dos grafos na análise de redes de competição em partidas profissionais de Counter-Strike: Global Offensive (CS:GO), um dos mais populares jogos de tiro em primeira pessoa, com um cenário competitivo profissional extenso e dinâmico. O objetivo é duplo: primeiro, identificar as maiores rivalidades e as conexões mais frequentes entre as equipes, e segundo, investigar como essas informações podem ser utilizadas estrategicamente para otimizar a programação de campeonatos de Counter-Strike. A análise concentra-se em dados históricos de partidas, onde equipes são representadas como nós e as partidas como arestas em um grafo ponderado. O peso das arestas reflete a frequência e a intensidade das rivalidades entre as equipes. A conclusão do estudo enfatiza o potencial da análise de grafos em revelar dinâmicas complexas no esporte eletrônico, oferecendo insights valiosos para jogadores, treinadores e organizadores de torneios em Counter-Strike.

Palavras-chave: Teoria dos Grafos; Algoritmo Strength of Ties; CS:GO; eSports; Rivalidades entre equipes; Programação de campeonatos; Análise Estratégica em eSports; Visualização de Dados.

I. INTRODUÇÃO

O mundo dos eSports tem crescido exponencialmente nos últimos anos, emergindo como um campo significativo no entretenimento e no esporte competitivo. Counter-Strike: Global Offensive (CS:GO) foi um dos mais populares eSports do mundo, sendo um jogo de tiro em primeira pessoa (FPS - First Person Shoot) que envolve estratégia, habilidade e trabalho em equipe. No cenário profissional de CS:GO, equipes de todo o mundo competem em torneios de alto nível, atraindo milhões de espectadores e gerando um volume significativo de dados sobre partidas, estratégias e desempenhos de jogadores.

A análise desses dados não é apenas de interesse para os fãs e jogadores, mas também oferece insights valiosos para treinadores, analistas e organizadores de torneios. Recentemente, a aplicação de técnicas estatísticas e computacionais, como a teoria dos grafos, emergiu como um método poderoso para desvendar padrões complexos e dinâmicas nas interações entre as equipes.

Neste contexto, o presente estudo visa aplicar a teoria dos grafos para analisar as redes de competição em partidas

profissionais de CS:GO, com um duplo objetivo: identificar as maiores rivalidades entre as equipes e investigar como essas informações podem ser utilizadas para otimizar a programação de campeonatos de Counter-Strike.

II. CONTEXTUALIZAÇÃO

A teoria dos grafos é uma disciplina matemática que estuda as propriedades e aplicações de grafos, uma representação de conjuntos de objetos em que alguns pares de objetos estão conectados por um elo. No contexto dos eSports e especificamente nesse estudo das competições de CS:GO, a teoria dos grafos foi utilizada para mapear e compreender as complexas redes de rivalidades entre as equipes. Através desta abordagem, os nós representam as equipes e arestas representam os confrontos entre elas, com pesos nas arestas refletindo a intensidade e frequência das rivalidades, o que fornece insights profundos sobre as dinâmicas competitivas do jogo.

Dentro dessa estrutura, o algoritmo de "Strength of Ties" (Força de Conexões) pode ser aplicado para quantificar a robustez das relações entre as equipes. Este algoritmo considera não apenas a presença de uma conexão, mas sua força, profundidade e significado, podendo ser derivado de fatores como histórico de competições, resultados e contextos sociais. Ao aplicar este algoritmo, foi possível identificar quais rivalidades têm maior impacto no cenário competitivo, quais partidas tem maior probabilidade de capturar mais a atenção dos espectadores e podem ser consideradas partidas-chave para a estruturação de torneios.

Ao analisar essas conexões fortes e utilizar esses dados de maneira estratégica, os organizadores de torneios podem planejar eventos que não apenas maximizem o engajamento do público desde o início, mas também mantenham o interesse até as finais. Assim, a teoria dos grafos, juntamente com o algoritmo de "Strength of Ties", oferece uma abordagem robusta e quantificável para otimizar a gestão e o marketing no campo em expansão dos eSports. Este estudo realça a aplicabilidade de tais análises no domínio dos eSports e sugere um

caminho promissor para futuras investigações analíticas que podem revelar ainda mais padrões significativos de competição e estratégia.

III. TRABALHOS CORRELATOS

Pesquisas anteriores no campo dos eSports frequentemente focaram em aspectos como *análise de desempenho de jogadores, estratégias de jogo e modelagem de simulações de partidas* [1]. No entanto, a aplicação da teoria dos grafos, um ramo da matemática aplicada que estuda as relações entre objetos, é relativamente nova no contexto dos eSports. *Estudos como Análise de redes sociais para a mídia social* [2] demonstraram como a teoria dos grafos pode ser utilizada para analisar redes sociais e sistemas complexos. No entanto, a exploração dessa abordagem no cenário competitivo de Counter-Strike, com a teoria dos grafos, ainda é um território pouco explorado, oferecendo um campo fértil para investigações.

Por outro lado, no estudo dos eSports, especialmente em jogos como CS:GO, outras abordagens têm sido utilizadas para analisar as dinâmicas competitivas. A literatura nesta área é vasta e variada, abordando desde análises estatísticas até o desenvolvimento de ferramentas de coleta de dados. Ademais dos dois citados acima, outros três trabalhos relevantes fornecem contextos e metodologias que complementam e contrastam com a presente pesquisa.

O primeiro, apresentado no "Journal of Applied Sport Management", *eSports Venues: A New Sport Business Opportunity* [13], explora a estrutura competitiva dos eSports através de um prisma gerencial e organizacional. Este estudo detalha as implicações da competição e do gerenciamento de equipes em um ambiente esportivo eletrônico, oferecendo um quadro de referência para entender como as dinâmicas de equipe e rivalidade influenciam o sucesso no campo.

Em seguida, um artigo disponível no SEGeT, *E-Sports: Um mercado rentável e pouco explorado* [14] foca na aplicação de análises estatísticas no eSports, especialmente voltadas para previsões e otimizações de resultados. Tal abordagem quantitativa fornece insights valiosos sobre as tendências de desempenho e o impacto de variáveis específicas na performance das equipes de CS:GO.

Por fim, a ferramenta "*HLTV-Scraper*" [15], disponível no GitHub ilustra um exemplo prático do desenvolvimento de tecnologia voltada para a coleta de dados no cenário dos eSports. Este scraper é projetado para extrair informações do site HLTV [16], uma referência mundial e número um em cobertura de Counter-Strike, demonstrando como a automatização pode facilitar a análise de grandes volumes de dados competitivos. Ademais, a coleta das informações utilizando essa ferramenta pode garantir a manutenção do banco de dados desse experimento ao longo dos anos, contribuindo veementemente para possíveis trabalhos futuros.

Cada um destes trabalhos contribui para uma compreensão mais rica do campo dos eSports e destaca a importância de diversas metodologias e ferramentas na análise de jogos como Counter-Strike. A combinação dessas perspectivas fornece

uma base sólida para futuras pesquisas e desenvolvimentos na área.

IV. METODOLOGIA

A. Coleta de Dados

Este estudo baseia-se em uma análise de um conjunto de dados abrangente, com cerca de mais de 25 mil confrontos, sobre *partidas profissionais de Counter-Strike: Global Offensive (CS:GO)* [3], extraído de uma fonte pública disponível no Kaggle [3]. Este banco de dados foi escolhido devido ao seu grande detalhamento e representatividade no panorama competitivo do CS:GO, cobrindo uma ampla gama de resultados de partidas durante determinado período, do ano de 2015 até 2020.

As informações coletadas de cada partida incluem variáveis cruciais que são fundamentais para a análise de rivalidades no eSports:

- **Data da Partida (date):** Fornece o contexto temporal de cada jogo, permitindo análises que consideram a evolução das rivalidades competitivas ao longo do tempo.
- **Nomes das Equipes (team_1 e team_2):** Essenciais para identificar os vértices no modelo de grafo e para estabelecer as conexões (arestas) entre as equipes.
- **Placares Alcançados (result_1 e result_2):** Utilizados para calcular os pesos das arestas no grafo, refletindo a intensidade e a competitividade das partidas.
- **Vencedor do Mapa (map_winner):** Oferece insights sobre o resultado geral, agregando uma camada adicional de profundidade à análise.
- **Ranking das Equipes (rank_1 e rank_2):** Informações sobre a posição no ranking mundial de cada equipe, permitindo uma avaliação mais matizada das forças relativas e da reputação das equipes no cenário global.

B. Modelagem de Grafos

A modelagem de grafos neste estudo é focada em analisar as relações competitivas entre as equipes de CS:GO ao longo do tempo. Utilizou-se uma abordagem que combina análises quantitativas com a teoria dos grafos para oferecer uma visão mais profunda das dinâmicas do eSports. Na construção deste modelo de grafo, adotou-se as seguintes abordagens:

- **Vértices:** Representam as equipes de CS:GO. Cada equipe que participou de ao menos uma partida no período analisado foi incluída no grafo, permitindo uma análise detalhada da rede de competições.
- **Arestas:** As arestas conectam pares de equipes que competiram entre si. Para cada par de equipes, criou-se uma aresta única, independentemente do número de confrontos diretos.
- **Peso das Arestas:** O peso de cada aresta é determinado não apenas pela frequência das partidas entre as equipes, mas também pela diferença nos resultados e pelas posições no ranking mundial naquele ano. Esta abordagem multifatorial permite avaliar a intensidade das rivalidades com maior precisão. Além disso, ajustes são feitos para considerar a consistência dessas relações

ao longo do tempo, usando um método que pondera a história de confrontos anteriores, refletindo assim a evolução das rivalidades.

- **Visualização:** O uso de cores distintas para cada equipe e a destacada visualização das rivalidades mais intensas (maior peso) em cada ano oferecem uma interpretação visual clara das relações no cenário do CS:GO. Isso é especialmente útil para identificar padrões significativos e mudanças nas dinâmicas competitivas ao longo dos anos.

Este modelo de grafo, enriquecido com ponderações multifatoriais e visualizações intuitivas, fornece insights valiosos sobre a evolução das rivalidades no CS:GO. A análise resultante não apenas destaca as conexões mais significativas entre as equipes, mas também revela como estas relações mudam ao longo do tempo, oferecendo uma ferramenta analítica robusta para o entendimento do cenário competitivo do eSports.

C. Análise dos Dados

Conduziu-se a análise dos dados coletados em etapas progressivas, cada uma desenhada para extrair diferentes camadas de dinâmicas de competição no CS:GO:

- **Análise Descritiva:** Realizou-se uma análise descritiva para capturar a distribuição geral das partidas. Examinou-se a frequência com que cada equipe competiu estabelecendo uma compreensão fundamental da atividade competitiva.
- **Análise de Rivalidades:** A partir dos dados históricos, calculou-se a intensidade das rivalidades entre as equipes. Utilizou-se um método que incorpora os resultados das partidas e os rankings mundiais, atribuindo-se pesos às arestas do grafo que refletem a frequência dos confrontos, criando um indicador quantitativo de rivalidade.
- **Análise Temporal:** Segmentou-se a análise anualmente para investigar como as relações e rivalidades evoluíram com o tempo. Permitiu-se então rastrear o desenvolvimento e as mudanças nas relações entre equipes, fornecendo uma visão dinâmica de como as estratégias e a competição se desdobram ao longo dos anos.
- **Visualização:** Empregou-se técnicas de visualização para criar representações gráficas dos grafos, destacando-se as rivalidades mais intensas e facilitando a compreensão dos padrões complexos. Isso foi instrumental tanto para a interpretação analítica quanto para a comunicação efetiva dos resultados.

V. RESULTADOS

Nesta etapa, detalha-se minuciosamente os procedimentos adotados, os experimentos realizados e os resultados obtidos.

A. Procedimentos Adotados

1) *Ambiente de Desenvolvimento:* Utilizou-se o Visual Studio Code (VS Code) [4] como ambiente de desenvolvimento integrado (IDE). Motivo da escolha devido à familiaridade do autor com a ferramenta.

Escolheu-se a linguagem de programação Python [5], devido sua simplicidade e eficiência, especialmente em tarefas

de manipulação de dados. O ecossistema de bibliotecas, como pandas, NetworkX e Matplotlib, que foram essenciais para este projeto, pesaram na escolha.

Empregou-se também a extensão Jupyter [6] do Visual Studio Code. Esta extensão integra as funcionalidades dos Jupyter Notebooks, uma ferramenta que oferece a execução de código Python em células separadas, facilitando a experimentação, a visualização de dados e a documentação do processo de análise de forma iterativa e interativa.

2) Bibliotecas Utilizadas:

- **pandas [7]:** Uma biblioteca de manipulação e análise de dados de alto nível, oferecendo estruturas de dados e operações para manipular tabelas numéricas e séries temporais.

Utilizou-se para carregar e preparar os dados do CSV (`pd.read_csv`), além de converter tipos de dados e filtrar o conjunto de dados.

- **networkx [8]:** Uma biblioteca para a criação, manipulação e estudo da estrutura, dinâmica e funções de redes complexas.

Aplicou-se para construir e manipular grafos, onde cada nó representa uma equipe e cada aresta representa uma partida entre equipes.

- **matplotlib.pyplot [9]:** Uma biblioteca de plotagem para a criação de gráficos estáticos, animados e interativos em Python.

Empregou-se para a visualização dos grafos, incluindo a configuração do layout, títulos e exibição de etiquetas.

- **matplotlib.colors [10]:** Um módulo da Matplotlib que oferece uma maneira de manipular cores e mapas de cores.

Valeu-se para gerar um mapa de cores que é usado para diferenciar as equipes no grafo de rivalidades.

```
1 Importar pandas como pd
2 Importar networkx como nx
3 Importar matplotlib.pyplot como plt
4 Importar matplotlib.colors como mcolors
```

3) *Conjunto de Dados do arquivo .csv:* Obteve-se o conjunto de dados a partir de *partidas profissionais de Counter-Strike: Global Offensive (CS:GO)* [3], uma coleção que inclui mais de 25.000 partidas registradas. O repositório de dados fornece quatro arquivos .csv: `economy.csv`, `picks.csv`, `players.csv` e `results.csv`. Para este projeto, optou-se pelo arquivo `results.csv`, considerando que este se alinha mais adequadamente com o problema proposto. Dentro do arquivo `results.csv`, há 19 colunas de informações, das quais selecionou-se 8 para uso (`date`, `team_1`, `team_2`, `result_1`, `result_2`, `rank_1`, `rank_2` e `map_winner`).

4) *Preparação dos Dados:* Define-se a equipe a ser analisada e carregam-se os dados do arquivo CSV para um DataFrame chamado `'df'`.

Converte-se a coluna com a data para o formato de data e adiciona-se uma nova coluna, que contém apenas o ano da data. As colunas de rank e resultado são convertidas para números, afim de facilitar análises numéricas.

O DataFrame é então filtrado para incluir apenas as partidas que envolvem a equipe desejada, resultando em um novo DataFrame filtrado.

Por fim, define-se a variável de rivalidade com o valor desejado para a análise das partidas. Quanto maior esse valor, maior a intensidade da rivalidade.

```
1 Definir team_to_analyze como 'SK'
2 Carregar dados arquivo CSV '../db/results.csv' em df
3
4 Converter coluna 'date' de df para formato de data
5 Adicionar coluna 'year' em df com o ano de 'date'
6 Converter colunas 'rank_1', 'rank_2', 'result_1', '
   result_2' de df para numero
7
8 Filtrar df para partidas que incluem team_to_analyze
   e armazenar em df_filtered
9
10 Definir minRivalry como 1.3
```

5) *Escolha do algoritmo utilizado:* Dentro do contexto do problema apresentado, optou-se pelo uso do algoritmo 'Strength of Ties' (Força de Conexão). Este algoritmo foi implementado com o objetivo de examinar as relações entre as equipes profissionais em jogos de CS:GO.

6) *Implementação do Algoritmo de Força de Conexão (Strength of Ties):* Utilizou-se este algoritmo para calcular a força das conexões (arestas) entre as equipes (vértices) com base na frequência dos confrontos e na importância das disputas, envolvendo cálculos diante do resultado da partida e a posição do ranking das equipes em questão.

```
1 Definir funcao calcular_peso_consistente com
   parametros (row, ano, grafos_anteriores)
2 Definir peso_atual baseado em resultado e rank
   das equipes
3 Adicionar 0.5 ao peso_atual se 'map_winner' for
   '1' ou '2'
4 Inicializar peso_consistente como 0
5 Para cada ano_anterior e grafo em
   grafos_anteriores
6     Se grafo tiver aresta entre as equipes da
   partida
7         Adicionar ao peso_consistente um valor
   baseado no peso da aresta e a diferenca de anos
8 Retornar peso_atual + peso_consistente
```

Identificou-se dessa forma, rivalidades onde as arestas mais fortes indicam uma alta frequência de confrontos ou partidas significativas entre as equipes.

7) *Construção do Grafo:* A construção do grafo envolve a criação de grafos anuais que representam as partidas e as rivalidades da equipe analisada. Isso é feito calculando um peso para cada partida e criando arestas com esses pesos entre as equipes envolvidas.

```
1 Inicializar graphs_by_year como um dicionario vazio
2
3 Para cada ano e grupo em df_filtered agrupado por '
   year'
4     Criar um grafo G
5     Para cada partida em grupo
6         Calcular peso usando
   calcular_peso_consistente
7         Determinar oponente da equipe analisada
8         Adicionar aresta ao grafo G com o peso
   calculado
```

```
9 Criar grafo H apenas com arestas de G que tem
   peso maior que minRivalry
10 Armazenar H em graphs_by_year com a chave sendo
   o ano
```

8) *Visualização do Grafo:* Realiza-se a visualização através da plotagem dos grafos, destacando-se as relações mais significativas (arestas com maior peso) e utilizando cores para diferenciar as equipes. Entende-se, que com esta visualização, ajuda a identificar melhor as equipes e as dinâmicas de competição e rivalidade ao longo do tempo.

```
1 Criar conjunto de equipes a partir de df
2 Gerar cores para as equipes
3
4 Se graphs_by_year estiver vazio
5     Exibir mensagem de que nao foram encontradas
   partidas
6 Senao
7     Para cada ano e grafo H em graphs_by_year
8         Criar figura para plotagem
9         Definir layout do grafo H
10        Determinar aresta de peso maximo e outras
   arestas normais
11        Desenhar arestas normais e aresta de peso
   maximo com estilos diferentes
12        Desenhar nos com cores especificas das
   equipes
13        Adicionar rotulos aos nos e etiquetas de
   peso as arestas
14        Definir titulo e ocultar eixos
15        Exibir grafico
16
17 Fim
```

B. Experimentos Realizados

Estruturaram-se os experimentos em células de um Jupyter Notebook, conforme descrito na seção de Ambiente de Desenvolvimento. Totalizando-se em 13 células distintas, sendo a última a que entrega o resultado final. O processo evolutivo das células foi o seguinte:

Esboçou-se a célula inicial com a plotagem de um grafo, utilizando-se do banco de dados já refinado. As células subsequentes desenvolveram-se adicionando funcionalidades incrementais, como:

- Implementação de um **limiar de rivalidade**.
- Utilização do algoritmo "Strength of Ties" para avaliar a intensidade dessas rivalidades.
- **Verificação** de correspondência dos dados retornados do banco de dados com os resultados do experimento.
- **Análise por ano**, permitindo a seleção de um ano e equipe específicos para análise detalhada.
- Expansão para incluir análises abrangendo **todos os anos disponíveis** no banco de dados.
- Melhorias na **visualização dos resultados**, incluindo a adição de cores para facilitar a interpretação.
- **Aprimoramento nos cálculos:** inicialmente focando na frequência das partidas, e posteriormente incorporando os resultados das partidas e a diferença nas posições de ranking, visando aprimorar a precisão e relevância dos resultados.

Concluindo-se a última célula do Jupyter Notebook, conduziram-se experimentos adicionais, nos quais se variaram

as variáveis independentes, tais como a seleção específica da equipe e o ajuste do limiar de rivalidade. O objetivo dessas variações era determinar quais configurações geram resultados mais significativos para o desafio proposto: identificar as maiores rivalidades em CS:GO e explorar a possibilidade de utilizar esses achados para aperfeiçoar estrategicamente a programação de campeonatos de Counter-Strike.

A progressão das células ao longo do projeto pode ser consultada no repositório GitHub intitulado 'Análise de Redes de Competição em Partidas Profissionais de CS:GO Utilizando Teoria dos Grafos' [11], onde está toda a evolução do trabalho.

C. Resultados Obtidos

Os resultados obtidos através desse experimento, considerando o período ao longo dos anos de 2016 a 2018, revelam um panorama dinâmico das rivalidades no cenário profissional de CS:GO. Os grafos representam as redes de competição da equipe 'SK Gaming' [12], destacando as conexões e a intensidade das rivalidades com outras equipes.

Rede de Competição de SK - Ano 2016

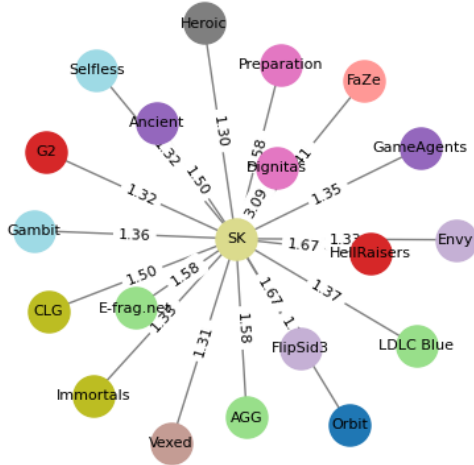


Fig. 1. Maiores rivalidades do time SK Gaming no ano de 2016.

1) 2016: A equipe SK destacou-se por intensas rivalidades com diversos adversários, com pontuações mais elevadas representando maior rivalidade. Notadamente, as equipes Dignitas e HellRaisers emergiram como as principais rivais, com índices de rivalidade de 3.09 e 1.67, respectivamente, indicando as frequências e competitividades mais elevadas dentre os confrontos.

Rede de Competição de SK - Ano 2017

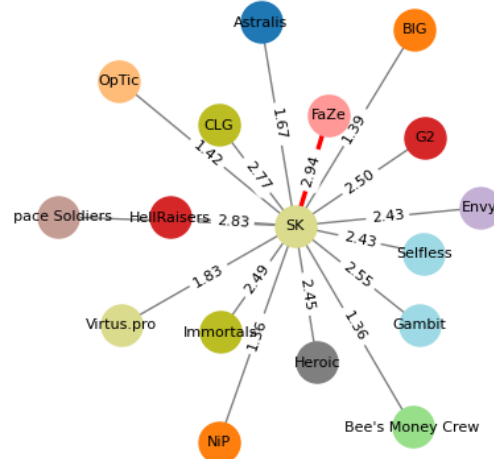


Fig. 2. Maiores rivalidades do time SK Gaming no ano de 2017.

2) 2017: A dinâmica competitiva da equipe SK ganhou novas dimensões com o surgimento de adversários notáveis. Em destaque, a FaZe sobressai como uma rival proeminente com um índice de 2.94, enquanto HellRaisers e CLG também se apresentam como competidores significativos, com valores de 2.83 e 2.77, respectivamente. É notória a consistência da HellRaisers, que persiste como uma rival da SK pelo segundo ano consecutivo, e o notável crescimento da Gambit, que saltou de 1.36 para 2.55.

Rede de Competição de SK - Ano 2018

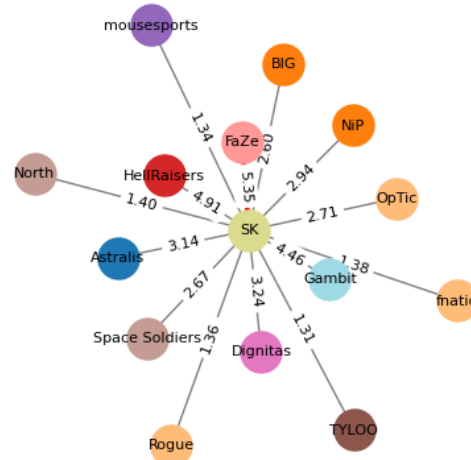


Fig. 3. Maiores rivalidades do time SK Gaming no ano de 2018.

3) 2018: A trama competitiva envolvendo a equipe SK mostra um dinamismo crescente, com certas rivalidades se consolidando e o advento de novas disputas. FaZe e HellRaisers permanecem como oponentes marcantes, registrando índices de rivalidade de 5.35 e 4.91, respectivamente. A

Gambit destaca-se ainda mais, alcançando o terceiro lugar em termos de rivalidade com a SK com um valor de 4.46. Notavelmente, a Astralis emerge como um novo competidor de peso, como denotado por um índice de rivalidade superior a 3.0. Ademais, a Dignitas, menos proeminente em 2017 em comparação a 2016, ressurge como um dos principais rivais.

4) *Conclusão*: Os resultados indicam uma dinâmica evolutiva nas relações competitivas da equipe SK. Essas informações podem ser cruciais para organizações de eventos, pois fornecem uma perspectiva estratégica sobre as rivalidades no eSport, com implicações diretas para a gestão e o marketing.

A representação gráfica dessas conexões competitivas, juntamente com a intensidade das rivalidades, tende a desempenhar um papel vital no desenvolvimento de narrativas de marketing e no planejamento estratégico. As métricas visuais, como a espessura das linhas e os valores numéricos associados, desvendam a recorrência e o significado das disputas, fundamentais para o engajamento da comunidade. Utilizando esses dados, os organizadores podem agendar confrontos relevantes em momentos-chave dos torneios, intensificando assim o envolvimento e a expectativa dos fãs, e integrando esses insights ao ciclo vital de promoção e gestão no ambiente dinâmico dos eSports.

VI. CONSIDERAÇÕES FINAIS

Os resultados obtidos sugerem que a suposição inicial de que é possível identificar as maiores rivalidades de CS:GO através da utilização da teoria de grafos e do algoritmo de Strength of Ties na análise de dados de partidas anteriores é factível. As redes de competição desenvolvidas e aprofundadas ao longo deste estudo revelaram não apenas as rivalidades existentes, mas também a intensidade e evolução destas ao longo do tempo. Consequentemente, esses achados podem fornecer uma base sólida que pode ser estrategicamente utilizada para otimizar a programação de campeonatos de Counter-Strike, com o potencial de intensificar a competitividade e o engajamento do público.

Em um desenvolvimento futuro deste trabalho, com mais tempo e recursos, a implementação de uma ferramenta analítica avançada seria um passo natural. Tal instrumento poderia sugerir, de forma concreta, como os campeonatos e organizadores poderiam estruturar os eventos para maximizar o engajamento da audiência durante todo o evento. Também pode ser explorado uma limitação significativa durante esse estudo, que reside na incapacidade de analisar aspectos sociais ou relações afetivas entre os jogadores, equipes e torcidas, o que pode impactar diretamente a percepção e a realidade das rivalidades. Esta ferramenta contemplaria as dinâmicas de rivalidade e forneceria recomendações programáticas personalizadas para capturar e manter o interesse dos espectadores, garantindo assim o sucesso contínuo e a relevância dos eventos de Counter-Strike no panorama dos esportes eletrônicos.

REFERÊNCIAS

- [1] M. N. Rizani and H. Iida, "Analysis of Counter-Strike: Global Offensive," 2018 International Conference on Electrical Engineering and

- Computer Science (ICECOS), Pangkal, Indonesia, 2018, pp. 373-378, doi: 10.1109/ICECOS.2018.8605213.
- [2] RECUERO, R.; BASTOS, M.; ZAGO, G. Análise de redes sociais para a mídia social. Porto Alegre: Sulina, 2015. 182 p.
- [3] MACHADO, M. D. CS:GO Professional Matches [Data set]. Kaggle. Disponível em: <https://www.kaggle.com/datasets/mateusdmachado/csgo-professional-matches>. Acesso em: 2023.
- [4] Visual Studio Code. Disponível em: <https://code.visualstudio.com/>. Acesso em: 2023
- [5] Python in Visual Studio Code. Disponível em: <https://code.visualstudio.com/docs/languages/python>. Acesso em: 2023.
- [6] Jupyter Notebooks in VS Code. Disponível em: <https://code.visualstudio.com/docs/datascience/jupyter-notebooks>. Acesso em: 2023.
- [7] Python Data Analysis Library. Disponível em: <https://pandas.pydata.org/>. Acesso em: 2023.
- [8] NetworkX Analysis in Python. Disponível em: <https://networkx.org/>. Acesso em: 2023.
- [9] Introduction to pyplot. Disponível em: <https://matplotlib.org/stable/tutorials/pyplot.html>. Acesso em: 2023.
- [10] Specifying Colors. Disponível em: <https://matplotlib.org/2.0.2/users/colormap>. Acesso em: 2023.
- [11] Análise de Redes de Competição em Partidas Profissionais de CS:GO Utilizando Teoria dos Grafos. Disponível em: <https://github.com/phpdias/teoria-dos-grafos-csgo>. Acesso em: 2023.
- [12] SK Gaming. Disponível em: <https://www.sk-gaming.com/>. Acesso em: 2023.
- [13] eSports Venues: A New Sport Business Opportunity Disponível em: <https://trace.tennessee.edu/jasm/vol10/iss1/8/>. Acesso em: 2023.
- [14] E-Sports: Um mercado rentável e pouco explorado. Disponível em: <https://www.aedb.br/seget/arquivos/artigos22/47033203.pdf>. Acesso em: 2023.
- [15] HLTV-Scraper. Disponível em: <https://github.com/nmwash/HLTV-Scraper>. Acesso em: 2023.
- [16] HLTV. Disponível em: <https://www.hltv.org/>. Acesso em: 2023.